

FACULDADE DE INFORMÁTICA E ADMINISTRAÇÃO PAULISTA — FIAP

Pós-Graduação em Inteligência Artificial para Desenvolvedores

PREDIÇÃO DE RISCO DE CÂNCER DO COLO DO ÚTERO

Classificação Supervisionada com Aprendizado de Máquina

Tech Challenge — Fase 1

Jefferson Antônio Pantoja Silva | jeffkd35@gmail.com

Wilson Lima da Silva | wilson.slima@gmail.com

Gustavo Lopes da Silva | gustavo_lsilva@hotmail.com

Felipe Soeiro Lopes | felipesoeiro.contato@outlook.com.br

Vinicius Tavares Sousa da Silva | viniciustavares2014@gmail.com

São Paulo

2026

RESUMO

O câncer do colo do útero é a quarta neoplasia maligna mais frequente entre mulheres no mundo, e sua detecção precoce é determinante para o prognóstico. O presente trabalho descreve o desenvolvimento de um sistema de triagem baseado em aprendizado de máquina utilizando o dataset Risk Factors Cervical Cancer, coletado no Hospital Universitário de Caracas, Venezuela, e disponível no UCI Machine Learning Repository. O dataset contém 858 registros com 36 variáveis — incluindo dados demográficos, hábitos de vida, histórico de doenças sexualmente transmissíveis (DSTs) e uso de contraceptivos — e apresenta forte desbalanceamento de classes: apenas 6,4% dos registros correspondem a biópsia positiva. Foram aplicadas técnicas de pré-processamento em pipeline encapsulado com scikit-learn, incluindo remoção de colunas sem variabilidade, imputação pela média com indicadores de missing, agrupamento de variáveis redundantes, transformação logarítmica e engenharia de features estratégicas. Três cenários de modelagem foram avaliados: (1) Random Forest com busca de hiperparâmetros via GridSearchCV; (2) Random Forest com SMOTE e ajuste de threshold para 0,41; e (3) Árvore de Decisão com parâmetros regulados. O melhor resultado foi obtido com Random Forest + SMOTE + threshold 0,41, alcançando Recall de 36% na classe positiva — um ganho de 4× em relação ao baseline — com AUROC de 0,737. Os resultados demonstram que o dataset, embora pequeno e desbalanceado, pode ser utilizado para fins de triagem com limitações conhecidas, mas não possui poder preditivo suficiente para aplicação clínica direta sem coleta de dados adicionais.

Palavras-chave: aprendizado de máquina; câncer do colo do útero; Random Forest; Árvore de Decisão; SMOTE; desbalanceamento de classes; triagem clínica.

ABSTRACT

Cervical cancer is the fourth most frequent malignant neoplasm among women worldwide, and early detection is critical for prognosis. This paper describes the development of a machine-learning-based screening system using the Risk Factors Cervical Cancer dataset, collected at the Hospital Universitario de Caracas, Venezuela, available at the UCI Machine Learning Repository. The dataset contains 858 records with 36 variables — including demographic data, lifestyle habits, history of sexually transmitted diseases (STDs) and contraceptive use — and presents strong class imbalance: only 6.4% of records correspond to positive biopsy. Preprocessing techniques were applied in an encapsulated sklearn pipeline, including removal of zero-variance columns, mean imputation with missing indicators, redundant variable grouping, logarithmic transformation, and strategic feature engineering. Three modeling scenarios were evaluated: (1) Random Forest with GridSearchCV hyperparameter search; (2) Random Forest with SMOTE and threshold adjustment to 0.41; and (3) Decision Tree with regulated parameters. The best result was achieved with Random Forest + SMOTE + threshold 0.41, reaching 36% Recall on the positive class — a 4× gain over baseline — with AUROC of 0.737. Results demonstrate that the dataset, while small and imbalanced, can be used for screening purposes with known limitations, but lacks sufficient predictive power for direct clinical application without additional data collection.

Keywords: machine learning; cervical cancer; Random Forest; Decision Tree; SMOTE; class imbalance; clinical screening.

SUMÁRIO

1 INTRODUÇÃO

2 REFERENCIAL TEÓRICO

2.1 Câncer do Colo do Útero e Triagem Clínica

2.2 Aprendizado de Máquina em Medicina

2.3 Desbalanceamento de Classes e SMOTE

3 METODOLOGIA

3.1 Dataset

3.2 Análise Exploratória de Dados

3.3 Pré-processamento e Engenharia de Features

4 MODELAGEM

4.1 Modelo 1 — Random Forest Baseline (GridSearchCV)

4.2 Modelo 2 — Random Forest + SMOTE + Threshold 0,41

4.3 Modelo 3 — Árvore de Decisão (sem SMOTE)

4.4 Comparativo de Resultados

5 DISCUSSÃO

6 CONCLUSÃO

REFERÊNCIAS

1 INTRODUÇÃO

O câncer do colo do útero representa um significativo problema de saúde pública mundial. Segundo a Organização Mundial da Saúde (OMS), esta é a quarta neoplasia mais frequente entre mulheres, com aproximadamente 600.000 novos casos diagnosticados e 340.000 óbitos registrados anualmente. No Brasil, o Instituto Nacional de Câncer (INCA) estima dezenas de milhares de casos novos por ano, sendo a região Norte a de maior incidência. O diagnóstico precoce é determinante para o prognóstico: casos detectados nos estágios iniciais têm taxa de sobrevivência em cinco anos superior a 90%, enquanto o diagnóstico tardio reduz essa taxa para menos de 20%.

Nesse contexto, o aprendizado de máquina surge como ferramenta promissora para apoio à triagem clínica, permitindo a identificação de padrões complexos em grandes volumes de dados clínicos que poderiam não ser evidentes para o olho humano. Modelos preditivos baseados em fatores de risco — como histórico sexual, uso de contraceptivos, presença de doenças sexualmente transmissíveis (DSTs) e dados demográficos — podem auxiliar profissionais de saúde na priorização de pacientes para exames confirmatórios.

Este trabalho apresenta o desenvolvimento de um classificador de risco de câncer do colo do útero utilizando o dataset Risk Factors Cervical Cancer do UCI Machine Learning Repository. O objetivo é avaliar a viabilidade de modelos de aprendizado de máquina para triagem, identificando as melhores técnicas de pré-processamento e modelagem para um dataset pequeno e fortemente desbalanceado. O trabalho é parte do Tech Challenge Fase 1 da Pós-Graduação em Inteligência Artificial para Desenvolvedores da FIAP.

As principais contribuições deste trabalho incluem: (i) pipeline de pré-processamento robusto com oito etapas de transformação encapsuladas com scikit-learn; (ii) avaliação comparativa de três cenários de modelagem com Random Forest e Árvore de Decisão; (iii) análise do impacto do SMOTE e ajuste de threshold no recall da classe positiva; e (iv) discussão das limitações clínicas dos modelos desenvolvidos.

2 REFERENCIAL TEÓRICO

2.1 Câncer do Colo do Útero e Triagem Clínica

O câncer do colo do útero é causado, na grande maioria dos casos, pela infecção persistente pelo Papilomavírus Humano (HPV), especialmente pelos subtipos de alto risco 16 e 18. Outros fatores de risco estabelecidos incluem o início precoce da atividade sexual, múltiplos parceiros sexuais, tabagismo, uso prolongado de contraceptivos hormonais orais, imunossupressão e histórico de DSTs. A progressão da doença é lenta e passa por estágios pré-cancerosos detectáveis, o que torna a triagem sistemática altamente eficaz.

Os principais exames de triagem e diagnóstico são: o Papanicolau (citologia cervical), exame padrão de rastreio; a colposcopia (Hinselmann), visualização direta do colo; o teste de Schiller, que detecta células anormais por reação ao iodo; e a biópsia, considerada o padrão ouro diagnóstico. O dataset utilizado neste trabalho contém resultados de todos os quatro exames, sendo a biópsia adotada como variável target principal por sua maior representatividade clínica.

2.2 Aprendizado de Máquina em Medicina

Modelos de aprendizado de máquina têm sido amplamente aplicados em problemas de classificação médica, como diagnóstico de câncer, predição de readmissão hospitalar e triagem de doenças crônicas. Algoritmos baseados em árvores de decisão — como Random Forest e Gradient Boosting — são especialmente adequados para dados clínicos estruturados por sua capacidade de capturar relações não lineares e interações entre variáveis, além de oferecerem métricas de importância de features que auxiliam na interpretação clínica.

O Random Forest, proposto por Breiman (2001), é um ensemble de árvores de decisão treinadas com subconjuntos aleatórios de features e amostras (bagging). Sua robustez a outliers e capacidade de generalização o tornam um dos algoritmos mais utilizados em benchmarks de dados clínicos. A Árvore de Decisão, por sua vez, oferece interpretabilidade superior — uma vantagem crítica em contextos médicos, onde a explicabilidade do modelo é frequentemente exigida.

2.3 Desbalanceamento de Classes e SMOTE

O desbalanceamento de classes é um desafio recorrente em problemas de triagem médica, onde a prevalência da condição de interesse é tipicamente baixa. Modelos treinados em datasets desbalanceados tendem a apresentar alta acurácia global mas baixo recall na classe minoritária — situação inaceitável em triagem clínica, onde falsos negativos representam riscos diretos à vida.

O SMOTE (Synthetic Minority Oversampling Technique), proposto por Chawla et al. (2002), é uma das técnicas mais utilizadas para tratar o desbalanceamento. O algoritmo gera amostras sintéticas da classe minoritária interpolando instâncias existentes no espaço de features, diferindo da simples replicação (oversampling ingênuo). Embora eficaz tecnicamente, o uso de SMOTE em contextos médicos é controverso, pois as amostras geradas não correspondem a casos reais, podendo introduzir viés nas estimativas de desempenho clínico.

Complementarmente, o ajuste de threshold de decisão é uma estratégia simples e eficaz para aumentar o recall: ao reduzir o limiar de probabilidade para classificação positiva (padrão de 0,50), o modelo aumenta a sensibilidade ao custo de menor precisão — tradeoff frequentemente desejado em triagem médica.

3 METODOLOGIA

3.1 Dataset

O dataset Risk Factors Cervical Cancer (Fernandes, Cardoso e Fernandes, 2017) foi coletado no Hospital Universitário de Caracas, Venezuela, e está disponível no UCI Machine Learning Repository (ID 383). Contém dados de 858 pacientes do sexo feminino, com 36 variáveis originais divididas em quatro categorias: dados demográficos, hábitos de vida, histórico de DSTs e resultados de exames.

Tabela 1 — Características Gerais do Dataset

Atributo	Valor
Total de pacientes	858
Variáveis originais	36
Targets disponíveis	4 (Hinselmann, Schiller, Citologia, Biópsia)
Target principal	Biópsia (padrão ouro diagnóstico)
Classe positiva (câncer)	55 pacientes — 6,4%
Classe negativa (saudável)	803 pacientes — 93,6%
Dados faltantes	Sim — registrados como '?' no original
Fonte	UCI Machine Learning Repository (ID 383)

Fonte: Fernandes, Cardoso e Fernandes (2017) — adaptado pelos autores.

As variáveis target — Hinselmann, Schiller, Citologia e Biópsia — representam resultados de quatro exames distintos. Para este trabalho, foram removidas as primeiras três como features e adotada a Biópsia como único target, por ser o método histológico de maior confiabilidade. Adicionalmente, as colunas Dx:Cancer, Dx:CIN, Dx:HPV e Dx, referentes a diagnósticos prévios que introduziriam vazamento de dados (data leakage), foram também excluídas.

A presença de dados faltantes ocorre porque parte das pacientes optou por não responder determinadas questões por razões de privacidade, especialmente aquelas relacionadas a hábitos sexuais e histórico de DSTs. No arquivo original, esses valores foram representados pelo caractere '?' e foram convertidos para NaN no início do processamento.

Tabela 2 — Taxas de Positividade por Variável Target

Exame	O que avalia?	% Positivo	Observação
Hinselmann	Colposcopia com ácido acético	4,1%	Diagnóstico visual
Schiller	Teste de iodo	8,6%	Alta sensibilidade
Citologia	Papanicolau	5,1%	Exame padrão de rastreio
Biópsia ★	Análise histológica — padrão ouro	6,4%	Target principal

Fonte: elaborado pelos autores.

3.2 Análise Exploratória de Dados

A análise exploratória revelou características importantes do dataset. As pacientes apresentam idade média de 26,8 anos (desvio padrão: 8,5), com mínimo de 13 e máximo de 84 anos — distribuição assimétrica positiva com outliers em idades avançadas. O número médio de parceiros sexuais é 2,5, com mediana 2 e máximo de 28, evidenciando outliers expressivos. A primeira relação sexual ocorreu em média aos 17 anos (dp: 2,8), com mínimo de 10 anos.

Em termos de prevalências comportamentais: 14,6% das pacientes são fumantes; 64,1% utilizam contraceptivos hormonais; 11,2% utilizam DIU; e 10,5% apresentaram alguma DST. As DSTs mais prevalentes são condilomatose vulvo-perineal (5,7%), sífilis (2,4%) e HIV (2,4%). As colunas STDs:AIDS e STDs:cervical condylomatosis apresentaram valor zero para todas as 858 pacientes, sendo removidas por ausência total de variabilidade.

NOTA: A matriz de correlação evidenciou relações fracas entre os atributos e a Biópsia. Os maiores coeficientes positivos foram: STDs:genital herpes (0,13), STDs:HIV (0,12) e STDs_respondido (0,11). Correlações fracas confirmam a natureza não linear do problema e justificam o uso de modelos baseados em árvores.

Tabela 3 — Estatísticas Descritivas das Principais Variáveis

Variável	Válidos	Média	Desv. Pad.	Mín.	Máx.
Idade	858 (100%)	26,8	8,5	13	84
Nº de Parceiros Sexuais	832 (97%)	2,5	1,7	1	28
Primeira Relação (anos)	851 (99%)	17,0	2,8	10	32
Nº de Gestações	802 (93%)	2,3	1,4	0	11
Fuma (0/1)	845 (98%)	14,6%	—	0	1
Contrac. Hormonal (0/1)	750 (87%)	64,1%	—	0	1
DIU (0/1)	741 (86%)	11,2%	—	0	1
DST (0/1)	753 (88%)	10,5%	—	0	1
DST — Tempo 1º diagnóst.	71 (8%)	6,1	5,9	1	22
Biópsia — target	858 (100%)	6,4%	—	0	1

Fonte: elaborado pelos autores com base no dataset UCI.

3.3 Pré-processamento e Engenharia de Features

Todo o pré-processamento foi encapsulado em um Pipeline da biblioteca imbalanced-learn, garantindo que as mesmas transformações sejam aplicadas de forma idêntica nos dados de treino e de teste, prevenindo vazamento de dados. O pipeline é composto por oito etapas sequenciais, descritas a seguir.

Etapas 1 — Remoção de colunas sem variabilidade: Remoção de STDs:AIDS e STDs:cervical condylomatosis, cujos 858 registros eram identicamente zero. Colunas sem variância não contribuem para o modelo.

Etapas 2 — Tratamento de nulos com indicador de missing: Para cada coluna com NaN: criação de coluna auxiliar _preenchido (1=respondido, 0=não respondeu) e imputação dos nulos pela média da coluna. A informação de recusa é preservada como feature — pacientes que não respondem sobre DSTs podem exibir padrão comportamental relevante.

Etapas 3 — Agrupamento de indicadores redundantes: Colunas _preenchido com padrão de resposta idêntico foram consolidadas em uma única coluna _respondido. Exemplo: as 11 variáveis de DST apresentam exatamente 87,76% de respostas — todas foram consolidadas em STDs_respondido.

Etapas 4 — Redução de redundância no tabagismo: As colunas Smokes (years) e Smokes (packs/year) foram combinadas em $\text{smoke_year_packs} = \text{anos_fumante} \times \text{maços_por_ano}$, representando exposição acumulada. Se Smokes=0, ambas as colunas são zeradas previamente.

Etapas 5 — Transformação logarítmica em variáveis demográficas: Aplicação de $\log_{1p}$ em Age, Number of sexual partners, First sexual intercourse e Num of pregnancies. Reduz o impacto de outliers e normaliza distribuições assimétricas, melhorando a aprendizagem em modelos baseados em distância.

Etapas 6 — Engenharia de features — contraceptivos: Criação de contraceptive_mid_risk (uso entre 3–15 anos, flag binária) e contraceptive_exposure ($\text{Hormonal_Contraceptives} \times \text{anos_de_uso}$). Consistência garantida: se HC=0, anos de uso é zerado.

Etapa 7 — Remoção de redundância entre STDs temporais: Remoção de STDs: Time since first diagnosis por apresentar redundância quase perfeita com STDs: Time since last diagnosis (correlação diagonal nos gráficos de dispersão), confirmada visualmente.

Etapa 8 — Criação de atributos estratégicos combinados: Criação de: sexual_risk (parceiros/idade), smoke_age_risk (smoke_year_packs/idade), has_std (binária: STDs > 0), std_age_risk (número_DSTs/idade) e combined_risk (parceiros × (HC+1) × (nDSTs+1)). Buscam capturar interações não lineares.

RESULTADO DO PRÉ-PROCESSAMENTO: O dataset passou de 29 colunas para aproximadamente 42 features enriquecidas, sem nenhum valor nulo. O pré-processamento melhorou a importância relativa das features criadas no modelo (confirmado pelo gráfico de feature importance), mas o ganho de correlação linear com a Biópsia foi marginal, confirmando que relações não lineares predominam neste problema.

Tabela 4 — Taxa de Resposta por Grupo de Variáveis

Grupo de Variáveis	% Respondidas	% Faltantes	Coluna Indicadora
DSTs (11 colunas)	87,8%	12,2%	STDs_respondido
Contraceptivos Hormonais	87,4%	12,6%	Hormonal Contraceptives_respondido
DIU	86,4%	13,6%	IUD_respondido
Número de Gestações	93,5%	6,5%	Num of pregnancies_respondido
Hábitos de Fumo	98,5%	1,5%	Smokes_respondido
Tempo desde diagnóst. DST	8,3%	91,7%	STDs: Time since first diag._respondido

Fonte: elaborado pelos autores.

4 MODELAGEM

A modelagem foi conduzida em três cenários progressivos, todos utilizando divisão de dados em 80% para treino e 20% para teste, com estratificação pela variável Biópsia (`stratify=y`) e semente aleatória fixa (`random_state=42`) para reprodutibilidade. O conjunto de teste contém 172 amostras, das quais 11 são positivas para câncer e 161 são negativas. O target é exclusivamente a coluna Biópsia.

MÉTRICA PRIORITÁRIA: Em triagem clínica, o Recall (sensibilidade) da classe positiva é a métrica mais crítica. Um falso negativo — paciente com câncer classificada como saudável — representa risco direto à vida. A acurácia global é enganosa em datasets desbalanceados: um modelo ingênuo que prediz 'sempre negativo' já alcança 94% de acurácia.

4.1 Modelo 1 — Random Forest Baseline (GridSearchCV)

O primeiro cenário utilizou o algoritmo Random Forest com tratamento mínimo de nulos (apenas imputação pela média, sem o pipeline completo de pré-processamento). O GridSearchCV foi aplicado para busca sistemática dos melhores hiperparâmetros via validação cruzada com 5 folds, otimizando o F1-Score da classe positiva.

Código 1 — Configuração do Modelo 1 (Random Forest Baseline)

```
from sklearn.model_selection import GridSearchCV
from sklearn.ensemble import RandomForestClassifier

# Grade de hiperparâmetros testada
param_grid = {
    'model__n_estimators': [200, 400],
    'model__max_depth': [None, 10],
    'model__min_samples_leaf': [1, 2, 4],
    'model__class_weight': [{0:1, 1:10}, {0:1, 1:20}]
}

GridSearchCV(pipeline, param_grid, cv=5, scoring='f1', n_jobs=-1)

# Melhor configuração encontrada pelo GridSearchCV:
RandomForestClassifier(
    class_weight={0: 1, 1: 10}, # penaliza 10x erros na classe positiva
    n_estimators=200,           # 200 arvores na floresta
    min_samples_leaf=1,
    random_state=42
)
```

Os resultados do Modelo 1 demonstram um padrão típico de modelos treinados em datasets desbalanceados: alta acurácia global (94%) sustentada pela excelente classificação da classe majoritária (negativa), mas recall extremamente baixo para a classe positiva (9%). De 11 casos de câncer no conjunto de teste, apenas 1 foi identificado corretamente. Este resultado é insatisfatório para aplicação clínica.

Tabela 5 — Resultados do Modelo 1 (Random Forest Baseline)

Classe	Precisão	Recall	F1-Score	Suporte
Saudável (0)	94%	99%	0,97	161
Câncer (1)	50%	9%	0,15	11
Acurácia geral	—	—	0,94	172

Fonte: elaborado pelos autores. Suporte = número de amostras no conjunto de teste.

4.2 Modelo 2 — Random Forest + SMOTE + Threshold 0,41

O segundo cenário incorpora o SMOTE (Synthetic Minority Oversampling Technique) ao pipeline, inserido entre as etapas de pré-processamento e o classificador. O SMOTE gera amostras sintéticas da classe minoritária interpolando instâncias existentes no espaço de features. Experimentos preliminares demonstraram que o SMOTE isolado piorava o F1-Score; a combinação SMOTE + class_weight foi decisiva para o ganho de desempenho.

Adicionalmente, o limiar de decisão (threshold) foi ajustado de 0,50 para 0,41. Em vez de classificar como positivo apenas quando a probabilidade predita supera 50%, o modelo passa a classificar como positivo para probabilidades acima de 41%, aumentando a sensibilidade ao custo de menor precisão — tradeoff clinicamente desejável em triagem.

Código 2 — Configuração do Modelo 2 (RF + SMOTE + Threshold)

```
from imblearn.over_sampling import SMOTE
from sklearn.ensemble import RandomForestClassifier

# Passo de oversampling no Pipeline (antes do classificador)
SMOTE(random_state=42)

# Classificador (SMOTE + class_weight combinados melhoram o F1)
RandomForestClassifier(
    class_weight={0: 1, 1: 10}, # penaliza 10x erros na classe positiva
    n_estimators=200,           # 200 arvores na floresta
    min_samples_leaf=1,
    random_state=42
)

# Ajuste do limiar de decisao (padrao = 0.50)
y_proba = pipeline_oversampling.predict_proba(X_test)[: , 1]
threshold = 0.41
y_pred = (y_proba > threshold).astype(int)
```

Tabela 6 — Resultados do Modelo 2 (RF + SMOTE + Threshold 0,41)

Classe	Precisão	Recall	F1-Score	Suporte
Saudável (0)	96%	94%	0,95	161
Câncer (1)	31%	36%	0,33	11
Acurácia geral	—	—	0,91	172

Fonte: elaborado pelos autores. Destaque: melhor resultado da classe positiva.

O Modelo 2 elevou o Recall da classe positiva de 9% para 36%, um ganho de 4× em relação ao baseline. O AUROC obtido foi de 0,737, indicando poder discriminatório moderado. O F1-Score da classe positiva subiu de 0,15 para 0,33.

Em contrapartida, a acurácia global reduziu de 94% para 91%, refletindo o aumento de falsos positivos — consequência esperada do ajuste de threshold.

4.3 Modelo 3 — Árvore de Decisão (sem SMOTE)

O terceiro cenário avaliou a Árvore de Decisão como alternativa ao Random Forest. Experimentos com SMOTE demonstraram piora nos resultados deste modelo — o oversampling foi mantido comentado no código. Os parâmetros foram definidos manualmente após análise de overfitting: `max_depth=4` limita a profundidade para generalização adequada, e `min_samples_leaf=5` exige ao menos 5 amostras por folha, prevenindo fragmentação excessiva. O ajuste de threshold também não trouxe ganho, mantendo-se o padrão de 0,50.

Código 3 — Configuração do Modelo 3 (Árvore de Decisão)

```
from sklearn.tree import DecisionTreeClassifier

# SMOTE testado e removido -- piora os resultados neste modelo
# ('smote', SMOTE(random_state=42)), # linha comentada no notebook

DecisionTreeClassifier(
    class_weight={0: 1, 1: 10}, # penaliza 10x erros na classe positiva
    max_depth=4,                # profundidade maxima -- evita overfitting
    min_samples_leaf=5,         # minimo 5 amostras por folha
    random_state=42
)

# Threshold padrao = 0.50 mantido -- ajuste nao trouxe melhoria
```

Tabela 7 — Resultados do Modelo 3 (Árvore de Decisão, sem SMOTE)

Classe	Precisão	Recall	F1-Score	Suporte
Saudável (0)	95%	91%	0,93	161
Câncer (1)	22%	36%	0,28	11
Acurácia geral	—	—	0,88	172

Fonte: elaborado pelos autores.

A Árvore de Decisão atingiu Recall de 36% — igual ao Random Forest com SMOTE — porém com precisão inferior (22% vs 31%) e AUROC de 0,624, resultado classificado como fraco. A vantagem deste modelo reside na interpretabilidade: a estrutura de árvore permite visualizar e auditar as regras de classificação, o que pode ser relevante em contextos clínicos que exigem explicabilidade regulatória.

4.4 Comparativo de Resultados

Tabela 8 — Comparativo Final dos Três Modelos

Modelo	Precisão (câncer)	Recall (câncer)	F1 (câncer)	Acurácia	AUROC	Veredicto
RF Baseline (GridSearchCV)	50%	9%	0,15	94%	—	Recall insuficiente
RF + SMOTE + Threshold 0,41 ★	31%	36%	0,33	91%	0,737	Melhor resultado
Árvore de Decisão (sem SMOTE)	22%	36%	0,28	88%	0,624	AUROC fraco

Fonte: elaborado pelos autores. ★ = melhor resultado.

ANÁLISE: O Modelo 2 (RF + SMOTE + Threshold 0,41) apresentou o melhor equilíbrio entre recall e AUROC. O Modelo 3 (Árvore de Decisão) atingiu o mesmo recall, mas com AUROC substancialmente inferior e menor precisão. O Modelo 1 (Baseline) tem a maior precisão na classe positiva (50%), mas ignora 91% dos casos reais de câncer.

5 DISCUSSÃO

Os resultados obtidos refletem os desafios inerentes ao uso de aprendizado de máquina em datasets clínicos pequenos e desbalanceados. O dataset Risk Factors Cervical Cancer apresenta limitações estruturais que restringem o potencial preditivo dos modelos: apenas 55 casos positivos em 858 registros (6,4%), alta taxa de dados faltantes em variáveis potencialmente informativas (>91% para tempo desde diagnóstico de DST), e correlações fracas entre os atributos e o target, sugerindo que o conjunto de variáveis disponíveis não captura plenamente os fatores determinantes do diagnóstico por biópsia.

O pré-processamento desenvolvido demonstrou eficácia em melhorar a representatividade das features: o gráfico de importância de variáveis evidenciou que atributos criados (como `sexual_risk`, `smoke_year_packs` e `combined_risk`) apresentaram importâncias comparáveis ou superiores aos atributos originais no modelo pós-processamento. Contudo, esse ganho de importância não se traduziu em melhoria significativa da correlação linear com a Biópsia (ganho máximo de 0,01), confirmando que o problema é predominantemente não linear.

O impacto do SMOTE foi ambíguo: isoladamente, o oversampling piorou o F1-Score, provavelmente por introduzir variância adicional com amostras sintéticas em um espaço de features de baixo poder discriminatório. A combinação SMOTE + `class_weight={0:1, 1:10}` foi o que produziu ganho real, sugerindo que o oversampling funciona como regularizador que, em conjunto com a penalização de classe, orienta o modelo para um ponto de equilíbrio mais favorável na curva precisão-recall.

O ajuste de threshold de 0,50 para 0,41 contribuiu com ganho adicional de Recall (de 18% para 36% com o modelo SMOTE), demonstrando que a calibração da probabilidade de saída do modelo é um grau de liberdade importante, especialmente em problemas com assimetria de custo entre erros Tipo I e Tipo II. Em triagem médica, a minimização de falsos negativos é prioritária, justificando thresholds mais baixos mesmo ao custo de maior taxa de falsos positivos.

A Árvore de Decisão apresentou AUROC significativamente inferior ao Random Forest (0,624 vs 0,737), refletindo a menor capacidade discriminatória do modelo single-tree. O fato de ambos atingirem Recall de 36% para a classe positiva sugere que esse é um teto estrutural imposto pelo poder preditivo do dataset, não pelo algoritmo. Para superar essa barreira, seria necessário enriquecer o dataset com novas features ou aumentar substancialmente o número de casos positivos.

NOTA SOBRE SMOTE E ÉTICA MÉDICA: Embora o SMOTE seja tecnicamente eficaz para tratar desbalanceamento, seu uso em modelos clínicos é controverso. As amostras geradas são sintéticas — não correspondem a casos reais — e podem introduzir viés na estimativa de desempenho real do modelo em produção. Esta é uma limitação importante que deve ser declarada em qualquer aplicação clínica do modelo.

6 CONCLUSÃO

Este trabalho desenvolveu e avaliou três modelos de aprendizado de máquina para triagem de risco de câncer do colo do útero, utilizando o dataset Risk Factors Cervical Cancer do UCI Machine Learning Repository. O pipeline de pré-processamento implementado — com oito etapas de transformação encapsuladas em sklearn — demonstrou eficácia em enriquecer as representações das features, melhorando a interpretabilidade dos modelos.

O melhor resultado foi obtido com Random Forest + SMOTE + threshold 0,41, alcançando Recall de 36% na classe positiva (câncer) — ganho de 4× em relação ao baseline (9%) — e AUROC de 0,737. Esses valores, embora representem melhoria expressiva, ainda são insuficientes para uso clínico real: um recall de 36% implica que 64% dos casos positivos seriam classificados como negativos, o que é clinicamente inaceitável sem supervisão médica complementar.

As principais conclusões deste trabalho são: (i) o dataset não possui poder preditivo suficiente para classificação clínica autônoma, sendo seu uso mais adequado como ferramenta de suporte à decisão médica; (ii) o pré-processamento é capaz de melhorar a importância das features, mas não supera as limitações estruturais de um dataset pequeno e desbalanceado; (iii) a combinação SMOTE + class_weight é superior ao uso isolado de qualquer uma das técnicas; e (iv) o ajuste de threshold é uma estratégia simples e eficaz para aumentar a sensibilidade do modelo.

Como trabalhos futuros, recomenda-se: (i) coleta de dados adicionais para ampliar o número de casos positivos (idealmente mais de 500); (ii) avaliação de algoritmos de boosting como XGBoost e LightGBM, que tendem a superar o Random Forest em datasets pequenos e desbalanceados; (iii) uso de validação cruzada estratificada com k=10 folds para estimativas mais robustas com poucos dados; (iv) análise da curva Precisão-Recall, mais informativa que AUROC para classes muito desbalanceadas; e (v) integração de dados de outros hospitais para enriquecer a base com mais casos positivos.

REFERÊNCIAS

BREIMAN, L. Random forests. Machine Learning, v. 45, n. 1, p. 5–32, 2001.

CHAWLA, N. V. et al. SMOTE: Synthetic Minority Over-sampling Technique. Journal of Artificial Intelligence Research, v. 16, p. 321–357, 2002.

FERNANDES, K.; CARDOSO, J. S.; FERNANDES, J. Transfer learning with partial observability applied to cervical cancer screening. In: IBERIAN CONFERENCE ON PATTERN RECOGNITION AND IMAGE ANALYSIS, 2017, Faro. Proceedings... Cham: Springer, 2017. p. 243–250.

INSTITUTO NACIONAL DE CÂNCER (INCA). Estimativa 2023: incidência de câncer no Brasil. Rio de Janeiro: INCA, 2022.

ORGANIZAÇÃO MUNDIAL DA SAÚDE (OMS). Cervical cancer. Geneva: WHO, 2022. Disponível em: <<https://www.who.int/news-room/fact-sheets/detail/cervical-cancer>>. Acesso em: abr. 2025.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, p. 2825–2830, 2011.

SCIKIT-LEARN. Imbalanced-learn documentation — version 0.10. 2023. Disponível em: <<https://imbalanced-learn.org>>. Acesso em: abr. 2025.

UCI MACHINE LEARNING REPOSITORY. Cervical Cancer Risk Factors Data Set. 2017. Disponível em: <<https://archive.ics.uci.edu/dataset/383/cervical+cancer+risk+factors>>. Acesso em: abr. 2025.