

FIAP — Faculdade de Informática e Administração Paulista

Pós-Graduação IA Para Desenvolvedores

Jefferson Antônio Pantoja Silva

Wilson Lima da Silva

Gustavo Lopes da Silva

Felipe Soeiro Lopes

Vinicius Tavares Sousa da Silva

**CLASSIFICAÇÃO DE FATORES DE RISCO DO
CÂNCER DO COLO DO ÚTERO
COM RANDOM FOREST**

Relatório Técnico

São Paulo — SP

2026

FIAP — Faculdade de Informática e Administração Paulista

Jefferson Antônio Pantoja Silva

Wilson Lima da Silva

Gustavo Lopes da Silva

Felipe Soeiro Lopes

Vinicius Tavares Sousa da Silva

CLASSIFICAÇÃO DE FATORES DE RISCO DO CÂNCER DO COLO DO ÚTERO COM RANDOM FOREST

Trabalho apresentado ao curso de Pós-Graduação IA Para Desenvolvedores da FIAP — Faculdade de Informática e Administração Paulista, como requisito parcial para avaliação do Tech Challenge — Fase 1.

Área de concentração: Machine Learning aplicado à saúde.

São Paulo — SP

2026

RESUMO

Este trabalho apresenta o desenvolvimento de um sistema de classificação para identificação de fatores de risco do câncer do colo do útero, utilizando técnicas de aprendizado de máquina aplicadas ao dataset Risk Factors Cervical Cancer, coletado no Hospital Universitário de Caracas, Venezuela, e disponível no UCI Machine Learning Repository. O dataset contém 858 registros de pacientes com 36 variáveis, abrangendo dados demográficos, comportamentais e histórico médico, com a variável alvo principal sendo o resultado da biópsia.

A análise exploratória revelou um dataset fortemente desbalanceado — apenas 6,4% dos casos apresentaram biópsia positiva — com significativa presença de dados faltantes decorrentes de recusas de resposta por questões de privacidade. O pré-processamento foi estruturado em um pipeline sklearn com oito etapas, incluindo tratamento de valores nulos com indicadores de missing, agrupamento de colunas redundantes, transformações logarítmicas e engenharia de features.

O modelo selecionado foi o Random Forest com ajuste de pesos de classe (`class_weight = {0: 1, 1: 14}`), alcançando 94% de acurácia global e F1-Score de 0,97 para a classe negativa. O principal desafio identificado foi o baixo Recall (9%) para a classe positiva, reflexo direto do reduzido número de casos positivos disponíveis para treinamento.

Palavras-chave: câncer do colo do útero; aprendizado de máquina; Random Forest; classificação; dados desbalanceados; pré-processamento; biópsia.

ABSTRACT

This paper presents the development of a classification system for identifying cervical cancer risk factors using machine learning techniques applied to the Risk Factors Cervical Cancer dataset collected at the University Hospital of Caracas, Venezuela. The dataset contains 858 patient records with 36 variables covering demographic, behavioral, and medical history data, with the primary target variable being the biopsy result. The exploratory analysis revealed a heavily imbalanced dataset — only 6.4% of cases had a positive biopsy — with significant missing data due to privacy-related refusals. The model achieved 94% overall accuracy with a Random Forest classifier using class weighting, but only 9% recall on the positive class, highlighting the limitations of small imbalanced medical datasets.

Keywords: cervical cancer; machine learning; Random Forest; classification; imbalanced data; preprocessing; biopsy.

SUMÁRIO

1	INTRODUÇÃO	6
2	DATASET E DESCRIÇÃO DOS DADOS	7
2.1	Origem e contexto	7
2.2	Variáveis e tipos	8
2.3	Link para download e repositório	9
3	ANÁLISE EXPLORATÓRIA DOS DADOS	10
3.1	Distribuição das variáveis alvo	10
3.2	Perfil demográfico e comportamental	10
3.3	Análise de dados faltantes	11
3.4	Análise de correlação	12
4	ESTRATÉGIAS DE PRÉ-PROCESSAMENTO	13
4.1	Pipeline de transformação	13
4.2	Tratamento de valores nulos	13
4.3	Feature Engineering	14
5	MODELOS UTILIZADOS E JUSTIFICATIVA	15
5.1	Random Forest	15
5.2	Configuração e split	16
6	RESULTADOS E INTERPRETAÇÃO	17
6.1	Métricas de desempenho	17
6.2	Interpretação dos resultados	18
7	DISCUSSÃO E CONCLUSÕES	19
8	INSTRUÇÕES DE EXECUÇÃO	20
8.1	Pré-requisitos	20
8.2	Passo a passo	20
8.3	Dependências	21
8.4	Vídeo de demonstração	21
	REFERÊNCIAS	22
	APÊNDICE A — CÓDIGO-FONTE COMPLETO	23

1 INTRODUÇÃO

O câncer do colo do útero é o quarto tipo de câncer mais comum entre mulheres no mundo, com estimativas de 660.000 novos casos e 350.000 mortes por ano, segundo dados da Organização Mundial da Saúde (OMS, 2023). A detecção precoce é fundamental para aumentar a taxa de sobrevivência, pois o diagnóstico em estágios iniciais permite tratamentos menos invasivos e com maiores chances de cura.

Neste contexto, técnicas de aprendizado de máquina têm sido aplicadas para auxiliar na triagem de pacientes com maior risco, funcionando como uma ferramenta de suporte à decisão clínica. O presente trabalho desenvolve um classificador para predição do resultado da biópsia cervical — considerado o "padrão ouro" entre os exames disponíveis — a partir de fatores de risco demográficos, comportamentais e histórico de DSTs.

O objetivo principal é construir um pipeline completo de machine learning: desde a análise exploratória dos dados até a entrega de um modelo funcional com avaliação rigorosa de desempenho, discutindo as limitações impostas pelo desbalanceamento de classes e pelo tamanho reduzido do dataset.

Checklist de Entregáveis — Tech Challenge Fase 1

Tabela de entregáveis conforme requisitos FIAP

Entregável	Status	Localização neste documento
Link do repositório Git	✓ Incluído	github.com/wilsonLima/tech-challenge-fase1
Código-fonte completo	✓ Incluído	Apêndice A
README.md com instruções de execução	✓ Incluído	Seção 8 — Instruções de Execução
Dockerfile	— N/A	Docker não utilizado; venv + pip
Dataset (link para download)	✓ Incluído	Seção 2.1 · UCI Machine Learning Repository
Resultados obtidos (gráficos e análises)	✓ Incluído	Seção 6 — Resultados + relatório visual HTML
Discussão da análise exploratória	✓ Incluído	Seção 3 — EDA
Estratégias de pré-processamento	✓ Incluído	Seção 4 — Pré-Processamento
Modelos usados e porquê	✓ Incluído	Seção 5 — Modelos
Resultados e interpretação dos dados	✓ Incluído	Seção 6.2 — Interpretação

Fonte: Os autores (2026) conforme requisitos do Tech Challenge Fase 1 — FIAP.

2 DATASET E DESCRIÇÃO DOS DADOS

2.1 Origem e contexto

O dataset utilizado é o Risk Factors Cervical Cancer, coletado no Hospital Universitário de Caracas, Venezuela, por Kelwin Fernandes, Jaime S. Cardoso e Jessica Fernandes. O dataset foi publicado no UCI Machine Learning Repository em 2017 (FERNANDES et al., 2017).

Tabela 1 — Características gerais do dataset

Atributo	Valor
Nome	Risk Factors for Cervical Cancer
Fonte	UCI Machine Learning Repository
Link de download	https://archive.ics.uci.edu/dataset/383/cervical+cancer+risk+factors
Arquivo local	risk_factors_cervical_cancer.csv
Total de instâncias	858 pacientes
Total de variáveis	36 (incluindo 4 variáveis alvo)
Ano de coleta	2003
Repositório do projeto	https://github.com/wilsonLima/tech-challenge-fase1

Fonte: Os autores (2026), com base em Fernandes et al. (2017).

Algumas pacientes optaram por não responder a determinadas questões por preocupações com privacidade, o que resultou em valores faltantes representados pelo caractere "?" no arquivo original. Esse comportamento é especialmente prevalente nas questões relacionadas a doenças sexualmente transmissíveis (DSTs) e uso de métodos contraceptivos.

2.2 Variáveis e tipos

Tabela 2 — Variáveis do dataset (seleção principal)

Variável	Tipo	Descrição
Age	int	Idade da paciente (anos)
Number of sexual partners	int	Número de parceiros sexuais
First sexual intercourse	int	Idade na primeira relação sexual
Num of pregnancies	int	Número de gestações
Smokes	bool	Paciente fumante (0/1)
Smokes (years)	int	Anos como fumante
Smokes (packs/year)	int	Maços de cigarro por ano
Hormonal Contraceptives	bool	Uso de anticoncepcional hormonal (0/1)
Hormonal Contraceptives (years)	int	Anos de uso de anticoncepcional hormonal
IUD	bool	Uso de DIU — dispositivo intrauterino (0/1)
IUD (years)	int	Anos de uso do DIU
STDs	bool	Histórico de DST (0/1)
STDs (number)	int	Número de DSTs diagnosticadas
STDs:condylomatosis	bool	Condilomatose
STDs:syphilis	bool	Sífilis
STDs:HIV	bool	HIV
STDs:HPV	bool	HPV — papilomavírus humano
STDs: Time since first diagnosis	int	Anos desde o primeiro diagnóstico de DST
STDs: Time since last diagnosis	int	Anos desde o último diagnóstico de DST
Dx:Cancer / Dx:CIN / Dx:HPV / Dx	bool	Diagnósticos prévios — REMOVIDOS (leakage potencial)
Hinselmann / Schiller / Citology	bool	Variáveis alvo auxiliares — removidas do input
Biopsy	bool	VARIÁVEL ALVO PRINCIPAL

Fonte: Fernandes et al. (2017), adaptado pelos autores.

2.3 Link para download e repositório

O dataset pode ser obtido diretamente no UCI Machine Learning Repository através do endereço: <https://archive.ics.uci.edu/dataset/383/cervical+cancer+risk+factors>. O arquivo deve ser salvo com o nome `risk_factors_cervical_cancer.csv` na raiz do repositório.

O código-fonte completo está disponível em: <https://github.com/wilsonLima/tech-challenge-fase1>

Estrutura do repositório:

```
tech-challenge-fase1/  
├── risk_factors_cervical_cancer.csv      # Dataset original (UCI)  
├── init_cervical_cancer.ipynb           # Notebook principal  
├── relatorio_cancer_cervical.html        # Relatório visual interativo  
├── relatorio_tecnico_abnt.docx           # Este relatório (Word/ABNT)  
└── README.md                           # Instruções de execução
```

3 ANÁLISE EXPLORATÓRIA DOS DADOS

3.1 Distribuição das variáveis alvo

O dataset contém quatro variáveis alvo, cada uma correspondendo a um tipo diferente de exame clínico. Todas apresentam taxas de positividade muito baixas, refletindo o comportamento esperado em estudos de triagem populacional onde a doença é rara.

Tabela 3 — Taxa de positividade das variáveis alvo

Exame	Descrição	Positivos	% Positivo
Hinselmann	Colposcopia com ácido acético	35	4,1%
Schiller	Teste de Schiller com solução de iodo	74	8,6%
Citologia	Papanicolau (esfregaço cervical)	44	5,1%
Biopsia (target principal)	Análise histológica — padrão ouro	55	6,4%

Fonte: Os autores (2026), calculado a partir do dataset.

A variável Biopsia foi selecionada como target principal por representar o método diagnóstico mais definitivo clinicamente. As demais variáveis alvo (Hinselmann, Schiller, Citologia) foram removidas do conjunto de features para evitar data leakage.

3.2 Perfil demográfico e comportamental

A análise estatística descritiva revelou um perfil de pacientes predominantemente jovens, com padrões de comportamento distintos que podem ser relacionados ao risco de desenvolvimento de câncer cervical.

Tabela 4 — Estatísticas descritivas das variáveis principais

Variável	Válidos	Média	Desvio P.	Mín.	Máx.
Idade (anos)	858 (100%)	26,8	8,5	13	84
Nº parceiros sexuais	832 (97%)	2,5	1,7	1	28
Primeira relação (anos)	851 (99%)	17,0	2,8	10	32
Nº gestações	802 (93%)	2,3	1,4	0	11
Fuma (%)	845 (98%)	14,6%	—	0	1
Contrac. Hormonal (%)	750 (87%)	64,1%	—	0	1
DIU (%)	741 (86%)	11,2%	—	0	1
DST (%)	753 (88%)	10,5%	—	0	1

Fonte: Os autores (2026), calculado a partir do dataset.

Os dados revelam uma população jovem com média de 26,8 anos, apresentando forte assimetria positiva na distribuição etária. A maioria das pacientes (64,1%) utiliza

contraceptivos hormonais, enquanto apenas 14,6% são fumantes e 10,5% apresentam histórico de DST.

3.3 Análise de dados faltantes

Os dados faltantes constituem um desafio central deste dataset. Pacientes optaram por não responder questões sensíveis, resultando em missings sistemáticos por grupos de variáveis relacionadas.

Tabela 5 — Percentual de dados faltantes por grupo

Grupo de Variáveis	Registros Válidos	% Faltante
STDs (todas as 11 variáveis de DST)	753 de 858	12,2%
Contraceptivos Hormonais (uso + anos)	750 de 858	12,6%
DIU (uso + anos)	741 de 858	13,6%
Número de gestações	802 de 858	6,5%
Hábitos de fumo	845 de 858	1,5%
Parceiros sexuais	832 de 858	3,0%
Tempo desde diagnóstico de DST	71 de 858	91,7%

Fonte: Os autores (2026), calculado a partir do dataset.

Variáveis sem variabilidade — removidas: As colunas STDs:AIDS e STDs:cervical condylomatosis apresentaram valor zero para todos os 858 registros, sem qualquer poder preditivo. Foram removidas antes do treinamento.

3.4 Análise de correlação

A matriz de correlação de Pearson foi calculada antes e após o pré-processamento para avaliar o ganho de linearidade das transformações aplicadas. Os resultados revelaram correlações fracas com a variável Biopsia em todos os atributos.

Tabela 6 — Maiores correlações com a variável Biopsia (antes do pré-processamento)

Variável	Correlação com Biopsia	Observação
STDs:genital herpes	+0,130	DST com maior correlação
STDs:HIV	+0,124	Correlação DST-câncer
STDs: Time since first diagnosis_respondido	+0,111	Indicador de missing informativo
STDs (presença)	+0,107	Histórico de DST
STDs: Number of diagnosis	+0,097	Número de diagnósticos
STDs:condylomatosis	+0,085	Condiloma
Hormonal Contraceptives (years)	+0,079	Exposição prolongada
Age	+0,056	Correlação fraca com idade

Fonte: Os autores (2026).

A ausência de correlações fortes (nenhuma acima de 0,15) confirma que o problema é essencialmente não linear. O ganho de correlação após as transformações foi marginal (máximo +0,011), reforçando a necessidade de um classificador não linear como o Random Forest.

4 ESTRATÉGIAS DE PRÉ-PROCESSAMENTO

4.1 Pipeline de transformação

Todo o pré-processamento foi encapsulado em um Pipeline do scikit-learn, garantindo que as mesmas transformações sejam aplicadas consistentemente no conjunto de treino e de teste, eliminando o risco de data leakage. O pipeline é composto por oito etapas sequenciais.

```
pipeline = Pipeline([
    ('remover',          FunctionTransformer(remover_colunas_sem_variacao)),
    ('faltantes',        FunctionTransformer(tratar_missing_com_indicador)),
    ('agrupar',          FunctionTransformer(agrupar_colunas_preenchido)),
    ('tabagismo',        FunctionTransformer(reduzir_redundancia_smokes)),
    ('transformar_demo', FunctionTransformer(transformar_demograficos_comportamentais)),
    ('contraceptivos',   FunctionTransformer(transformar_contraceptivos)),
    ('remover_std_tempo', FunctionTransformer(remover_coluna_std_tempo)),
    ('novos_atributos',  FunctionTransformer(criar_atributos_estrategicos)),
    ('model',            RandomForestClassifier(class_weight={0:1, 1:14},
random_state=42))
])
```

4.2 Tratamento de valores nulos

A estratégia de tratamento dos valores nulos combina imputação por média com a criação de Missing Indicators — uma abordagem mais sofisticada que a simples remoção ou imputação isolada.

Para cada coluna com valores faltantes, foi criada uma nova coluna binária com sufixo `_preenchido`, assumindo valor 1 quando a paciente respondeu a questão e 0 quando se recusou. Os valores nulos foram então substituídos pela média da coluna.

Justificativa da abordagem: A simples remoção de linhas com dados faltantes reduziria o dataset de 858 para ~600 registros (perda de ~30%), comprometendo a já escassa classe positiva. O uso exclusivo da média apagaria a informação de que a paciente se recusou a responder — comportamento estatisticamente relevante. A combinação média + indicador preserva ambas as informações.

Após verificar que variáveis do mesmo grupo temático apresentavam padrões de resposta idênticos, as colunas indicadoras redundantes foram consolidadas em uma única coluna representativa por grupo, reduzindo a dimensionalidade sem perda de informação.

4.3 Feature Engineering

Além do tratamento de dados faltantes, foram aplicadas as seguintes transformações para enriquecer o conjunto de features:

(a) Transformação logarítmica: aplicada via `np.log1p()` nas variáveis demográficas e comportamentais contínuas (Age, Number of sexual partners, First sexual intercourse, Num of pregnancies), reduzindo o impacto de outliers e suavizando distribuições assimétricas.

(b) Consolidação do tabagismo: as colunas `Smokes (years)` e `Smokes (packs/year)` foram multiplicadas, criando a feature `smoke_year_packs` — uma medida de exposição acumulada ao tabaco.

(c) Feature Engineering de contraceptivos: criadas duas novas features: `contraceptive_mid_risk` (indicador binário de uso entre 3 e 15 anos) e `contraceptive_exposure` (produto entre uso e anos de uso).

(d) Atributos estratégicos combinados: foram criadas features que combinam múltiplas variáveis — `sexual_risk` (número de parceiros / idade), `std_age_risk` (número de DSTs / idade), `combined_risk` ($\text{parceiros} \times \text{contraceptivos} \times \text{DSTs}$).

5 MODELOS UTILIZADOS E JUSTIFICATIVA

5.1 Random Forest

O algoritmo selecionado foi o Random Forest Classifier, pertencente à família de métodos ensemble baseados em bagging. O Random Forest constrói múltiplas Árvores de Decisão sobre subamostras aleatórias do conjunto de treino, tanto em instâncias quanto em features, e produz a predição final por votação majoritária.

A justificativa para a escolha do Random Forest fundamenta-se em suas propriedades favoráveis para este problema específico:

- **Robustez a outliers:** a estrutura de particionamento binário das árvores é menos sensível a valores extremos que modelos lineares;
- **Dados mistos:** o algoritmo lida nativamente com variáveis binárias, categóricas e contínuas sem normalização;
- **Relações não lineares:** captura interações complexas que as correlações lineares da EDA mostraram ser necessárias;
- **Resistência ao overfitting:** o bagging e a aleatorização de features reduzem a variância sem aumentar o viés;
- **Ajuste de pesos de classe:** o parâmetro `class_weight` permite penalizar diferentemente os erros em classes desbalanceadas.

Outros algoritmos foram considerados — incluindo KNN (K-Nearest Neighbors), testado com normalização `MinMaxScaler` — mas o Random Forest demonstrou desempenho superior, motivando sua escolha como modelo final.

5.2 Configuração e split

Tabela 7 — Configuração do modelo e da divisão treino/teste

Parâmetro	Valor	Justificativa
class_weight	{0: 1, 1: 14}	Penaliza 14× os erros na classe positiva, refletindo proporção ~1:14
random_state	42	Garante reprodutibilidade dos resultados
test_size	0,20 (20%)	172 amostras no teste, 686 no treino
stratify=y	Biopsy	Mantém proporção de positivos (6,4%) em ambos os conjuntos
Estimador	Pipeline sklearn	Encapsula pré-processamento + modelo, evitando data leakage

Fonte: Os autores (2026).

O split estratificado garantiu que os 11 casos positivos no conjunto de teste (correspondendo a 6,4% de 172 amostras) refletissem a distribuição real do dataset.

Sobre o KNN testado: O KNN foi avaliado com `n_neighbors=5` e normalização `MinMaxScaler`. Os resultados foram inferiores ao Random Forest, especialmente no Recall da classe positiva, motivando a escolha definitiva pelo ensemble.

6 RESULTADOS E INTERPRETAÇÃO

6.1 Métricas de desempenho

O modelo Random Forest com pipeline completo foi avaliado no conjunto de teste (172 amostras, sendo 11 positivas e 161 negativas). As métricas obtidas são apresentadas na tabela a seguir.

Tabela 8 — Classification Report — Random Forest (conjunto de teste)

Classe	Precisão	Recall	F1-Score	Suporte
0 — Saudável	0,94	0,99	0,97	161
1 — Biopsia Positiva (Câncer)	0,50	0,09	0,15	11
Acurácia	—	—	0,94	172
Macro avg	0,72	0,54	0,56	172
Weighted avg	0,91	0,94	0,91	172

Fonte: Os autores (2026), saída do scikit-learn.

A acurácia global de 94% é elevada, porém enganosa como métrica principal em datasets desbalanceados. Um classificador ingênuo que sempre prediz "saudável" (classe 0) já alcançaria 93,6% de acurácia sem qualquer aprendizado.

6.2 Interpretação dos resultados

O Recall de 9% significa que, dos 11 casos reais de biópsia positiva no conjunto de teste, o modelo identificou corretamente apenas 1 (ou no máximo 2). Os demais foram classificados como falsos negativos — pacientes com câncer que o modelo não identificou.

Implicação clínica — Falsos Negativos: Em aplicações médicas de triagem, o custo de um falso negativo (não identificar um caso de câncer) é incomparavelmente maior que o de um falso positivo. Um sistema com Recall de 9% seria inadequado para uso clínico sem ajustes significativos de threshold ou dados adicionais.

A Precisão de 50% para a classe positiva indica que, das vezes que o modelo predisse "câncer", metade estava correta — significativamente acima do baseline aleatório (~6,4%).

O parâmetro `class_weight={0:1, 1:14}` forçou o modelo a penalizar mais os erros na classe positiva. No entanto, a limitação estrutural — apenas 55 casos positivos no dataset inteiro (44 no treino, 11 no teste) — impede que o modelo generalize bem para a classe minoritária.

Tabela 9 — Análise da matriz de confusão estimada

	Predito: Saudável	Predito: Câncer
Real: Saudável (161)	~160 (VP negativo)	~1 (FP)
Real: Câncer (11)	~10 (FN)	~1 (VP positivo)

Fonte: Os autores (2026), estimado a partir do classification report.

7 DISCUSSÃO E CONCLUSÕES

O trabalho demonstrou a viabilidade de construir um pipeline completo de machine learning para classificação de risco cervical, desde a análise exploratória até a avaliação do modelo, utilizando ferramentas Python de código aberto.

A análise exploratória revelou os principais desafios do problema: desbalanceamento extremo de classes (6,4% positivos), dados faltantes sistemáticos, correlações fracas com a variável alvo e presença de outliers. Essas características motivaram as estratégias de pré-processamento adotadas — Missing Indicators, transformações logarítmicas e criação de features combinadas.

O Random Forest com ajuste de pesos de classe demonstrou ser uma escolha adequada para este problema, capturando relações não lineares que as correlações lineares não revelavam. A estrutura de pipeline do scikit-learn garantiu a correta aplicação das transformações sem vazamento de informação do teste para o treino.

A principal limitação identificada foi o baixo Recall (9%) para a classe positiva — uma consequência direta do pequeno número de casos positivos disponíveis para treinamento. Para aplicação clínica real, este valor seria inaceitável.

Como trabalhos futuros, recomenda-se:

- **Aplicar SMOTE** (Synthetic Minority Over-sampling Technique) para aumentar artificialmente a classe positiva no treino;
- **Ajustar o threshold de decisão:** utilizar `predict_proba()` com threshold de 0,25 a 0,35 em vez do padrão 0,50;
- **Otimizar hiperparâmetros:** aplicar GridSearchCV ou Optuna para `n_estimators`, `max_depth`, `min_samples_leaf`;
- **Avaliar por AUC-ROC e Curva Precisão-Recall**, métricas mais adequadas para datasets desbalanceados;
- **Explorar algoritmos gradient boosting** como XGBoost ou LightGBM;
- **Coletar mais dados**, especialmente de casos positivos, para melhorar a capacidade de generalização.

Em síntese, este trabalho cumpriu seus objetivos de desenvolver e avaliar um pipeline de machine learning para um problema médico real, identificando com rigor tanto os resultados obtidos quanto as limitações, e propondo caminhos concretos para melhoria futura.

8 INSTRUÇÕES DE EXECUÇÃO

8.1 Pré-requisitos

- Python 3.8 ou superior
- pip (gerenciador de pacotes Python)
- Git (para clonar o repositório)

8.2 Passo a passo

1. Clonar o repositório:

```
git clone https://github.com/wilsonLima/tech-challenge-fase1
cd tech-challenge-fase1
```

2. (Recomendado) Criar e ativar ambiente virtual:

```
python -m venv venv

# Linux / Mac
source venv/bin/activate

# Windows
venv\Scripts\activate
```

3. Instalar as dependências:

```
pip install pandas numpy matplotlib seaborn scikit-learn jupyter
```

4. Baixar o dataset (já incluído no repositório):

```
# Acesse: https://archive.ics.uci.edu/dataset/383/cervical+cancer+risk+factors
# Salve como: risk_factors_cervical_cancer.csv (raiz do repositório)
```

5. Executar o notebook:

```
jupyter notebook init_cervical_cancer.ipynb
```

No Jupyter, clique em Kernel → Restart & Run All para executar todas as células sequencialmente e reproduzir os resultados completos.

8.3 Dependências

Tabela 10 — Bibliotecas e versões recomendadas

Biblioteca	Versão Recomendada	Uso no Projeto
pandas	≥ 1.5	Manipulação e análise de dados
numpy	≥ 1.23	Operações numéricas e transformações log
matplotlib	≥ 3.6	Gráficos de distribuição e pairplot
seaborn	≥ 0.12	Heatmap de correlação e histogramas
scikit-learn	≥ 1.2	Pipeline, Random Forest, métricas, split
jupyter	≥ 1.0	Ambiente interativo de notebooks

Fonte: Os autores (2026).

8.4 Vídeo de demonstração

A demonstração em vídeo do sistema em execução está disponível no YouTube/Vimeo com duração de até 15 minutos, cobrindo: (i) apresentação do dataset e análise exploratória; (ii) execução do pipeline de pré-processamento; (iii) treinamento e avaliação do modelo; (iv) interpretação dos resultados e discussão das limitações.

Nota: Não foi utilizado Docker neste projeto. O ambiente é gerenciado diretamente com venv e pip. Caso seja necessário containerizar no futuro, um Dockerfile padrão com imagem python:3.11-slim seria suficiente.

REFERÊNCIAS

FERNANDES, K.; CARDOSO, J. S.; FERNANDES, J. Transfer Learning with Partial Observability Applied to Cervical Cancer Screening. In: Iberian Conference on Pattern Recognition and Image Analysis, 2017. Springer, Cham, 2017. p. 243–250.

UCI MACHINE LEARNING REPOSITORY. Cervical Cancer (Risk Factors) Data Set. Disponível em: <<https://archive.ics.uci.edu/dataset/383/cervical+cancer+risk+factors>>. Acesso em: 2026.

BREIMAN, L. Random Forests. Machine Learning, v. 45, n. 1, p. 5–32, 2001.

CHAWLA, N. V. et al. SMOTE: Synthetic Minority Over-sampling Technique. Journal of Artificial Intelligence Research, v. 16, p. 321–357, 2002.

ORGANIZAÇÃO MUNDIAL DA SAÚDE (OMS). Cervical Cancer. Disponível em: <<https://www.who.int/news-room/fact-sheets/detail/cervical-cancer>>. Acesso em: 2026.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, p. 2825–2830, 2011.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. NBR 6023: Informação e documentação — Referências — Elaboração. Rio de Janeiro: ABNT, 2018.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. NBR 14724: Informação e documentação — Trabalhos acadêmicos — Apresentação. Rio de Janeiro: ABNT, 2011.

APÊNDICE A — CÓDIGO-FONTE COMPLETO

Arquivo: `init_cervical_cancer.ipynb` — seções principais reproduzidas abaixo.

A.1 Importações

```
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
import seaborn as sb

from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import classification_report
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import FunctionTransformer
from sklearn.preprocessing import StandardScaler, MinMaxScaler
```

A.2 Tratamento de valores nulos com Missing Indicators

```
def tratar_missing_com_indicador(dataset):
    dt = dataset.copy()
    for col in dt.columns:
        if dt[col].isnull().any():
            dt[f"{col}_preenchido"] = dt[col].notnull().astype(int)
            dt[col] = dt[col].fillna(dt[col].mean())
    return dt
```

A.3 Agrupamento de colunas indicadoras redundantes

```
def agrupar_colunas_preenchido(df, sufixo='_preenchido',
                                novo_sufixo='_respondido'):
    df = df.copy()
    colunas = [col for col in df.columns if sufixo in col]
    grupos = {}
    for col in colunas:
        valores = tuple(df[col].values)
        grupos.setdefault(valores, []).append(col)
    for grupo in grupos.values():
        if len(grupo) > 1:
            nome_base = grupo[0].replace(sufixo, '')
            nova_coluna = f"{nome_base}{novo_sufixo}"
            df[nova_coluna] = df[grupo[0]]
            df.drop(columns=grupo, inplace=True)
        else:
            df.rename(columns={grupo[0]: grupo[0].replace(sufixo, novo_sufixo)},
                      inplace=True)
    return df
```

A.4 Feature Engineering — Tabagismo e Contraceptivos

```
def reduzir_redundancia_smokes(df):
    df = df.copy()
    df.loc[df['Smokes'] == 0, ['Smokes (years)', 'Smokes (packs/year)']] = 0
    df['smoke_year_packs'] = df['Smokes (years)'] * df['Smokes (packs/year)']
    df.drop(columns=['Smokes (years)', 'Smokes (packs/year)'], inplace=True)
    return df

def transformar_demograficos_comportamentais(df):
```

```

df = df.copy()
for col in ['Age', 'Number of sexual partners',
            'First sexual intercourse', 'Num of pregnancies']:
    if col in df.columns:
        df[col] = np.log1p(df[col])
return df

def transformar_contraceptivos(df):
    df = df.copy()
    df.loc[df['Hormonal Contraceptives'] == 0,
           'Hormonal Contraceptives (years)'] = 0
    df['contraceptive_mid_risk'] = (
        (df['Hormonal Contraceptives'] == 1) &
        (df['Hormonal Contraceptives (years)'].between(3, 15))
    ).astype(int)
    df['contraceptive_exposure'] = (
        df['Hormonal Contraceptives'] *
        df['Hormonal Contraceptives (years)']
    )
    return df

```

A.5 Pipeline e treinamento do modelo final

```

dataset = pd.read_csv("risk_factors_cervical_cancer.csv", na_values='?')

pipeline = Pipeline([
    ('remover', FunctionTransformer(remover_colunas_sem_variacao)),
    ('faltantes', FunctionTransformer(tratar_missing_com_indicador)),
    ('agrupar', FunctionTransformer(agrupar_colunas_preenchido)),
    ('tabagismo', FunctionTransformer(reduzir_redundancia_smokes)),
    ('transformar_demo', FunctionTransformer(transformar_demograficos_comportamentais)),
    ('contraceptivos', FunctionTransformer(transformar_contraceptivos)),
    ('remover_std_tempo', FunctionTransformer(remover_coluna_std_tempo)),
    ('novos_atributos', FunctionTransformer(criar_atributos_estrategicos)),
    ('model', RandomForestClassifier(
        class_weight={0: 1, 1: 14},
        random_state=42
    ))
])

targets = ['Hinselmann', 'Schiller', 'Citology', 'Biopsy']
cols_drop = ['Dx:Cancer', 'Dx:CIN', 'Dx:HPV', 'Dx']

X = dataset.drop(columns=targets + cols_drop)
y = dataset['Biopsy']

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, stratify=y, random_state=42
)

pipeline.fit(X_train, y_train)
y_pred = pipeline.predict(X_test)
print(classification_report(y_test, y_pred))

```

A.6 Saída do Classification Report

	precision	recall	f1-score	support
0	0.94	0.99	0.97	161
1	0.50	0.09	0.15	11
accuracy			0.94	172
macro avg	0.72	0.54	0.56	172
weighted avg	0.91	0.94	0.91	172

A.7 Análise de correlação

```
# Maiores correlações com Biopsy (antes do processamento)
#   STDs:genital herpes      +0.130
#   STDs:HIV                +0.124
#   STDs (respondido)       +0.111
#   STDs (presença)         +0.107
#   STDs: N° diagnósticos   +0.097
#   Hormonal Contr. (anos)  +0.079
#   STDs:condylomatosis     +0.085
#   Age                     +0.056

# Ganho máximo após transformações: +0.011 (Num of pregnancies)
# Conclusão: problema essencialmente não linear
```

Fim do Relatório Técnico

FIAP — Pós-Graduação IA Para Desenvolvedores — Tech Challenge Fase 1 — 2026

Jefferson Antônio Pantoja Silva · Wilson Lima da Silva · Gustavo Lopes da Silva

Felipe Soeiro Lopes · Vinicius Tavares Sousa da Silva